

זיהוי אובייקטים

ישי גרוניך וברק עוגב

בחירת הנושא - אופנועים

הנושא שבחרנו הוא אופנועים, מאחר שבעוד שאופנועים הוא מאוד שונים זה מזה, לכולם יש מכנה משותף - גלגלים, כידון, צורה דומה, ופרטים נוספים.

יצירת אוסף תמונות

בפרוייקט שלנו 4 תיקיות של תמונות, ושמותיהן: neg, pos, test_neg, test_pos. בתיקות neg pos ישנן תמונות ששימשו לאימון המסווג, והתמונות בתיקות test_neg, test_pos נועדו לבדיקת המסווג, כלומר לתת ציוני precision, recall. רוב התמונות התיקית pos הן פשוטות, וזאת על מנת לאמן את המסווג בצורה היעילה ביותר (כאילו שהאופנוע סומן במלבן). בתיקית test_pos ישנן גם תמונות עם רקע מסובך, או עם אופנוע בזזית, או עם מריחה כתוצאה מתזוזה מהירה. ברוב התמונות האופנוע יחסית נמצא באמצע התמונה, אך ניתן היה להכליל את האלגוריתם ולהשתמש בחלון-zz על מנת לחפש את האופנוע בכמה אזורים שונים של תמונה גדולה יותר.

בניית ההיסטוגרמות ובחירת תכונות features

על מנת לבחור features, חישבנו SIFT Features לכל התמונות החיוביות, כלומר כל התמונות בתיקית pos, וושמנו את כל אותם features במערך אחד, עליו ביצענו K Means. ערך K זה, המסומן בקוד בתור FEATURES_NUM, הוא פרמטר הניתן לשינוי. לאחר שאלגוריתם K Means החזיר K ערכים, השתמשנו בהם בתור features על מנת לכל תמונה היסטוגרמה. מימד ההיסטוגרמה הוא FEATURES_NUM, והיא נבנית כך: בהנתן תמונה מסוימת, מחשבים לה SIFT Features, ולאחר מכן מוצאים לכל SIFT Feature את ה-feature הדומה לנו ביותר (לפי מרחק אוקלידי) מבין אלה שנבחרו על ידי K Means. כלומר, ההיסטוגרמה היא ספירה של כמה features יש מכל סוג.

בחירת המסווג Classifier

בשלב של בחירת המסווג ניסינו מספר מסווגים שונים. גילינו תוצאות טובות עבור RandomDecisionForest ועבור KNearestNeighbors, ובחרנו במסווג KNearestNeighbors. הפרמטר K, המסומן בקוד בתור המשתנה N_NEIGHBORS_DEFAULT, גם הוא פרמטר הניתן לשינוי.


הרצה עם פרמטרים שונים

שני הפרמטרים המשפיעים על תוצאות הסיווג הם `N_NEIGHBORS_DEFAULT` וגם `FEATURES_NUM`. לכן ניסינו זוגות שונים של שני הפרמטרים האלו. התוצאות מוצגות בגרפים הבאים ובו סומן קו אדום המסמן את האזור של הפרמטרים המהווים את העקומה ROC Curve (בתוספת שתי הנקודות הקיצוניות).

הרצה על תמונות האימון


הרצנו את המסווג על תמונות האימון, באמצעות פרמטרים שונים. נשים לב שכאשר הפרמטר `N_NEIGHBORS_DEFAULT` הוא נמוך, אך מתקיים `overfitting` לתמונות האימון ולכן התוצאות הן גבוהות מאוד. בפרט כאשר $k=1$, ערכי precision recall הם 1, ומאחר שזוהי נקודה יוצאת דופן ואין לה חשיבות (שהרי היא מדגימה רק `overfitting`), ללא כללנו אותה בגרף של ROC. להלן הגרפים שהתקבלו:

עבור הרצה על כל התמונות האימון:



הפרמטרים הטובים ביותר הם `FEATURES_NUM` שהוא 15 עם `N_NEIGHBORS_DEFAULT` שהוא 3 ועבורם מתקבל ערך precision של 0.82 וערך recall של 0.96.

עבור הרצה על תמונות האימון מהרמות השונות:




כאשר הצבע האדום מסמן את התמונות הפשוטות, הצבע הירוק את התמונות הבינוניות, והצבע הכחול את התמונות המסובכות.

- עבור התמונות הפשוטות, הפרמטרים הטובים ביותר הם FEATURES_NUM שהוא 15 עם N_NEIGHBORS_DEFAULT שהוא 3 ועבורם מתקבל ערך precision של 0.76 וערך recall של 1.
- עבור התמונות הבינוניות, הפרמטרים הטובים ביותר הם FEATURES_NUM שהוא 15 עם N_NEIGHBORS_DEFAULT שהוא 3 ועבורם מתקבל ערך precision של 0.41 וערך recall של 0.818.
- עבור התמונות המסובכות, הפרמטרים הטובים ביותר הם FEATURES_NUM שהוא 15 עם N_NEIGHBORS_DEFAULT שהוא 3 ועבורם מתקבל ערך precision של 0.375 וערך recall של 0.9375.

מעניין להוכיח כי הפרמטרים האופטימליים היו 15,3 בכל אחד מארבעת הגרפים בסעיף זה.


הרצה על תמונות הבדיקה

הרצנו את המסווג על תמונות הבדיקה, באמצעות פרמטרים שונים. להלן הגרפים שהתקבלו:



הפרמטרים הטובים ביותר הם `FEATURES_NUM` שהוא 12 עם `N_NEIGHBORS_DEFAULT` שהוא 9 ועבורם מתקבל ערך precision של 0.89 וערך recall של 0.86.

עבור הרצה על תמונות הבדיקה מהרמות השונות:



כאשר הצבע האדום מסמן את התמונות הפשוטות, הצבע הירוק את התמונות הבינוניות, והצבע הכחול את התמונות המסובכות.

- עבור התמונות הפשוטות, ישנם כמה פרמטרים שנותנים את הזוג precision recall הגבוה ביותר, שהוא בעל ערך precision של 0.84 וערך recall של 1. אחד מזוגות הפרמטרים הוא בעל ערך FEATURES_NUM של 15 וערך N_NEIGHBORS_DEFAULT של 12.
- עבור התמונות הבינוניות, הפרמטרים הטובים ביותר הם FEATURES_NUM שהוא 15 עם N_NEIGHBORS_DEFAULT שהוא 3 ועבורם מתקבל ערך precision של 0.81 וערך recall של 0.78. אחד מזוגות הפרמטרים הוא בעל ערך FEATURES_NUM של 15 וערך N_NEIGHBORS_DEFAULT של 12.
- עבור התמונות המסובכות, הפרמטרים הטובים ביותר הם FEATURES_NUM שהוא 18 עם N_NEIGHBORS_DEFAULT שהוא 9 ועבורם מתקבל ערך precision של 0.61 וערך recall של 0.66.

תמונות שסווגו לא נכון

להלן שתי תמונות של אופנועים שאנחנו סימנו בתור רמת סיבוכיות **בינונית**, אך (באופן מפתיע) זוהו על ידי רבים מהמסווגים בתור לא-אופנועים (כלומר False Negative):



המשותף לשתי התמונות הוא החלקים בעלי העניין בהם, שאינם אופניים לתמונה של אופנוע. בתמונה השמאלית ישנם העצים שברקע התמונה, ובתמונה הימנית ישנם הציורים על האופנוע וגם הלבנים המרכיבות את הקיר שמאחור.



להלן תמונה שאין בהן אופנועים אך רבים מהמסווגים זיהו אותה שיש בה (כלומר False Positive):



קשה להסביר מדוע דווקא התמונה הזו סווגה כאופנוע בעוד אחרות לא.

ניסיון לשפר את תוצאות הסיווג

עד כה, החלטנו לעבוד עם המסווג KNearestNeighbors כי מתוך כמה בדיקות ראינו שהתוצאות שלו טובות. בשלב זה, על מנת לנסות לשפר את תוצאות הסיווג, בדקנו מסווגים רבים, מסווגים שונים, גם כאלה שלא הכרנו לפני כן. הצלחנו לשפר את תוצאות הסיווג, אך לרוב לא בשני הצירים precision, recall אלא רק אחד מהם - כלומר, ייתכן שאחראי על מערכת היה בוחר במסווג KNearestNeighbors אם היו חשובים לו precision וגם recall באותה המידה, ואילו ייתכן שהיה בוחר באחד המסווגים הבאים אם אחד הפרמטרים precision או recall היו חשוב לו יותר מאשר השני. מתוך התוצאות השונות, התוצאות המרשימות ביותר הן עבור AdaBoost ועבור RandomDecisionForest שעבורם קיבלנו ערכי precision מאוד גבוהים (עד 1).



התמונה הימנית היא עקומת ROC עבור המסווג AdaBoost. הערכים של precision ושל recall, משמאל לימין בהתאמה, בכל אחד מהנקודות המעניינות, הם:
(0.92, 0.82) (0.958, 0.807) (0.976, 0.719)

התמונה השמאלית היא עקומת ROC עבור המסווג Random Forest. הערכים של precision ושל recall, משמאל לימין בהתאמה, בכל אחד מהנקודות המעניינות, הם:
(0.957, 0.789) (0.977, 0.77) (1.0, 0.67)

לאור העלייה במדד precision, כלומר ירידה במספר ערכי False Positives באופן יחסי, רצינו לבדוק האם התמונת "המופע הסיני" מהסעיף הקודם סווגה נכון על ידי המסווגים החדשים. עבור רוב הפרמטרים שבדקנו, התמונה סווגה כראוי, כלומר המסווג זיהה שבתמונה אין אופנוע.